AlertaP

Detección temprana de sismos con deep learning

Javier Eduardo España Pacheco (23361)
Angel Esteban Esquit Hernández (23221)
CC3092 Deep Learning y Sistemas Inteligentes
Universidad del Valle de Guatemala

Noviembre de 2026

Resumen

AlertaP es un prototipo de alerta temprana sísmica que recibe ventanas de un sismógrafo de tres componentes, detecta la llegada de la onda P y estima cuántos segundos quedan antes de la onda S. Implementa un detector profundo de dos capas ocultas, un baseline STA/LTA y un dashboard de demostración. La evaluación usa 60 ventanas reproducibles (30 eventos y 30 de ruido) y reporta error de picking, precisión, recall, F1, latencia y valor económico neto. La decisión central del proyecto es tratar el umbral como una decisión operativa: bajar el umbral puede ganar anticipación, pero aumenta falsas alarmas y paros innecesarios.

1. Problema, usuario y criterios de éxito

Guatemala está en una zona de alta actividad sísmica. Para una planta industrial, una señal temprana puede permitir detener maquinaria, cerrar una válvula de gas o avisar a las personas antes de la llegada de la onda S, que suele ser más destructiva. El usuario objetivo es el operador de una instalación con sensores sísmicos y acciones automáticas definidas; el producto le entrega una alerta, probabilidad, instante estimado y anticipación.

La hipótesis de partida es que un umbral fijo sobre la energía (STA/LTA) se degrada con ruido cultural, variación de estación y amplitud, y que un modelo profundo, que aprende patrones temporales y combina las tres componentes, compensa esa degradación. Esta hipótesis se contrasta con un baseline justo en la sección de evaluación y, como se verá, **no se confirma** sobre los datos sintéticos actuales. No se afirma que el prototipo sea un sistema certificado: su objetivo académico es medir el intercambio entre calidad técnica y valor de negocio.

Criterios de éxito: recall ≥ 0.80 en ventanas con evento; precisión ≥ 0.80 en el punto de operación elegido; error absoluto medio de picking < 0.30 s; latencia local < 2 s; y valor positivo bajo los costos explícitos.

2. Datos y pipeline

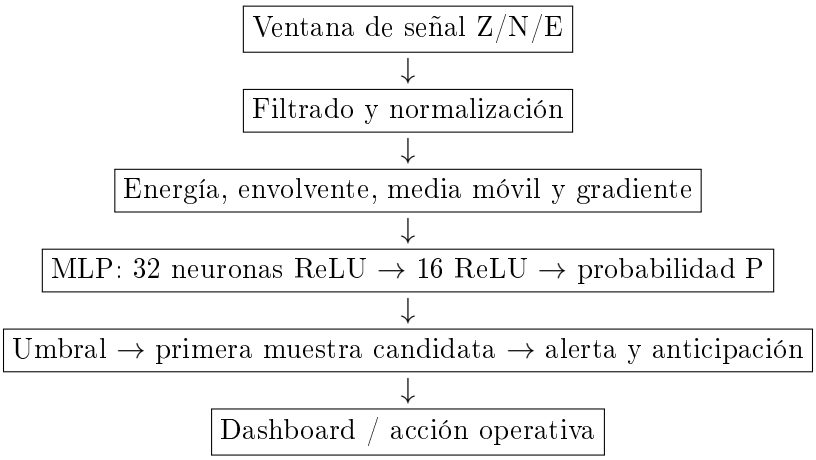
2.1. Fuente y preparación

La propuesta define STEAD (Stanford Earthquake Dataset), con más de un millón de registros de tres componentes y llegadas P/S etiquetadas, como fuente principal. También propone validar con estaciones de Guatemala mediante FDSN/IRIS cuando haya disponibilidad. En esta entrega se implementa una

capa sintética controlada para que el repositorio y las métricas sean ejecutables sin descargar gigabytes ni depender de red. Cada ventana dura 12 s a 100 Hz y contiene Z, N y E. Los eventos tienen una llegada P entre 2 y 5 s, una llegada S entre 1 y 2.8 s después, ruido gaussiano y ondas amortiguadas; las ventanas negativas contienen únicamente ruido. La semilla por defecto es 23361.

Para una integración real, los registros STEAD/FDSN deben convertirse a la misma forma $(T, 3)$, normalizarse por ventana, conservar sus etiquetas P/S y separarse por evento/estación para evitar fuga entre entrenamiento y prueba. La señal se filtra con un pasa-banda Butterworth de 1–18 Hz.

2.2. Arquitectura



El modelo recibe cuatro variables por instante agregadas sobre las tres componentes. Se entrena con Adam, 160 iteraciones máximas, validación interna 15 %, early stopping y semilla fija. Es una aproximación reproducible y liviana a PhaseNet/EQTransformer; la siguiente iteración sustituye el extractor por una CNN 1-D o fine-tuning de un picker preentrenado con STEAD.

3. Modelo, baseline y decisión de umbral

El baseline es STA/LTA causal: compara la energía media de una ventana corta de 0.25 s contra una larga de 3 s, ambas calculadas solo con muestras pasadas, y alerta cuando el cociente supera un umbral (2.0, elegido por valor en validación). Igual que DeepPhase, ignora el primer segundo, afectado por transitorios del filtro. El modelo evaluado es DeepPhase, un MLP de dos capas ocultas que estima $P(P \mid x_t)$. La inferencia selecciona la primera muestra cuyo valor supera el umbral de decisión, que se elige por valor de negocio en un conjunto de validación (0.85; ver sección 5).

El problema es de deep learning supervisado sobre series temporales: el modelo debe producir una decisión numérica auditable. La experiencia de usuario comunica probabilidad, latencia, detector clásico y segundos hasta S. Una probabilidad no se presenta como certeza.

4. Evaluación

El conjunto contiene 60 ventanas: 30 con evento y 30 de ruido, generadas con semillas y distribuciones documentadas. La división conceptual es por ventana; para validar con STEAD se debe dividir por evento y estación. Se reportan:

- **Error de picking:** $|t_{\text{pred}} - t_P|$ en segundos.

- **Precisión/recall/F1:** un acierto exige aviso útil: alerta no anterior a $t_P - 0.5$ s y anterior a la llegada de S. Una alerta tardía o prematura cuenta como evento no detectado (FN).
- **Latencia:** tiempo de inferencia del detector.
- **Valor:** función de la sección 5, con costos explícitos de falsas alarmas, eventos no detectados y operación.

La división es de tres conjuntos independientes: entrenamiento (semilla 23361), validación de 120 ventanas (semilla 777), donde se elige el umbral por valor, y prueba de 60 ventanas (semilla 2026), donde se reportan los resultados. La evaluación se ejecuta con `.venv/bin/python src/evaluate.py` y guarda `results/metrics.json`; así no se reportan números escritos a mano.

Cuadro 1: Métricas en el conjunto de prueba, cada sistema en el umbral elegido por valor en validación.

Sistema	Umbral	Precisión	Recall	F1	Error P (s)	Valor neto
STA/LTA	2.0	**1.0000**	**1.0000**	**1.0000**	**0.0937**	**$57,980**
DeepPhase	0.85	0.9375	1.0000	0.9677	0.1907	$53,040

La latencia media de DeepPhase es de aproximadamente 0.4 ms y la anticipación media lograda es de 1.94 s antes de la onda S en ambos sistemas. Bajo los supuestos de la sección 5, **STA/LTA produce $4,940 más de valor neto que DeepPhase** (dos falsas alarmas de DeepPhase cuestan $5,000). Con un baseline justo (causal y con la misma exclusión inicial), el modelo profundo no mejora al clásico en estos datos: la señal sintética tiene una relación señal/ruido alta y una llegada P de energía clara, por lo que un cociente de energías ya la separa casi perfectamente. Estas cifras corresponden al conjunto sintético reproducible y no deben interpretarse como desempeño en producción.

La implementación actual procesa ventanas completas; todavía no es un servicio de streaming causal. El dashboard permite cambiar el umbral. Un umbral menor puede aumentar recall y anticipación, pero también FP; uno mayor reduce falsos disparos y puede perder el inicio de un evento. La política correcta depende del costo real de detener una planta versus el costo del daño evitado, que es lo que formaliza la siguiente sección.

5. Modelo de valor

5.1. Función de valor

Para un conjunto de N ventanas, el valor neto en USD es

$$V = TP \cdot \bar{a} \cdot v_s \;-\; FP \cdot c_{fa} \;-\; FN \cdot c_{fn} \;-\; N \cdot c_{op},$$

donde $\bar{a}$ es la anticipación media lograda (segundos entre la alerta y la llegada de S). La anticipación se mide por evento y se limita a $[0,\, t_S - t_P]$: una alerta anterior a P no es aviso útil y una posterior a S no aporta valor.

5.2. Curva de valor y punto de operación

El valor se calcula para cada umbral (figura 1). El umbral se elige maximizando el valor en el conjunto de validación, no la métrica técnica, y se reporta sobre el conjunto de prueba. Ambos conjuntos coinciden en 0.85 para DeepPhase. Entre 0.55 y 0.80 el valor es plano ($48,040 en prueba) porque el número de

Cuadro 2: Supuestos del modelo de valor. Todos son estimaciones, no datos medidos.

Parámetro	Valor	Justificación
v_s	\$1,000/s	Pérdida evitada por segundo de aviso (paro de maquinaria, cierre de gas, aviso al personal) en una planta mediana.
c_{fa}	\$2,500	Paro innecesario: producción detenida y reinicio.
c_{fn}	\$10,000	Daño adicional de un evento sin aviso; 4 veces el costo de una falsa alarma.
c_{op}	\$1 por ventana	Cómputo y operación amortizados; inferencia de ≈0.4 ms.

falsas alarmas no cambia; a 0.85 se eliminan 2 falsas alarmas más sin perder eventos, y a 0.90 el recall cae a 0.73 y el valor se vuelve negativo (–\$42,060). El óptimo queda por tanto junto a un precipicio: en producción conviene un margen de seguridad.

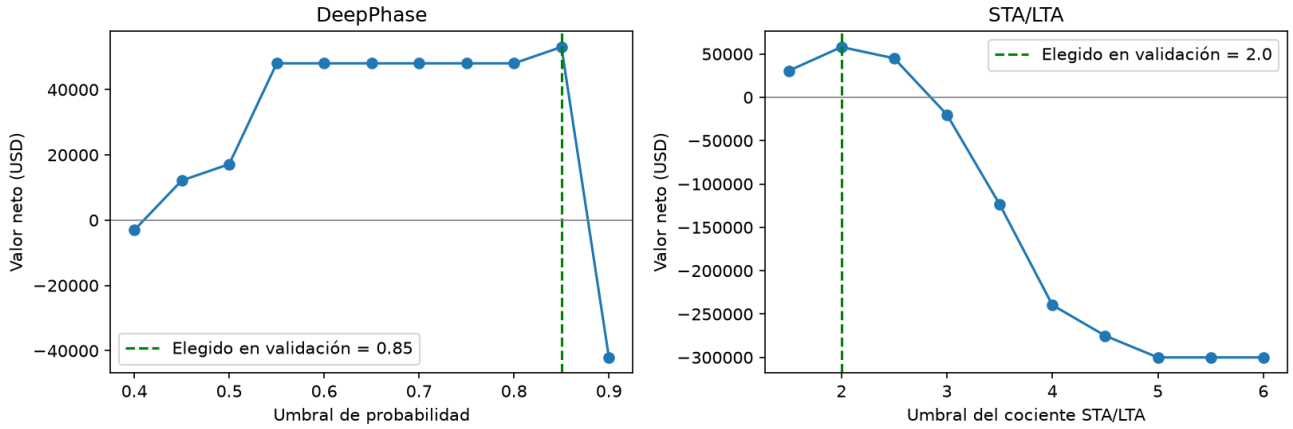


Figura 1: Valor neto en el conjunto de prueba al variar el umbral.

5.3. Análisis de sensibilidad

Cada supuesto se varió ±20 % y ±50 % manteniendo los demás. La tabla muestra el valor neto de DeepPhase en el umbral 0.85 (base: \$53,040).

Cuadro 3: Valor neto de DeepPhase en prueba al variar cada supuesto.

Supuesto	−50 %	−20 %	+20 %	+50 %
v_s (valor por segundo)	\$23,990	\$41,420	\$64,660	\$82,090
c_{fa} (falsa alarma)	\$55,540	\$54,040	\$52,040	\$50,540
c_{fn} (evento perdido)	\$53,040	\$53,040	\$53,040	\$53,040

El valor es sobre todo sensible a v_s, y su signo no cambia en ningún escenario. c_{fn} no afecta a DeepPhase en 0.85 porque en prueba no deja eventos sin detectar, pero sí castiga a los umbrales más altos. El umbral óptimo elegido en validación se mantiene en 0.85 en los 12 escenarios. La diferencia con STA/LTA (que en su umbral óptimo de 2.0 no tiene falsos negativos ni falsas alarmas) es negativa para DeepPhase en todos los escenarios, entre –\$2,440 y –\$7,440: ningún supuesto económico razonable cambia el orden.

6. Producto y experiencia de usuario

Se ejecuta con `streamlit run src/app.py`. El operador selecciona si la ventana contiene un evento, ajusta el umbral y pulsa "Analizar ventana". La gráfica muestra la componente Z, las llegadas P/S verdaderas en la demo y las detecciones. Se muestran simultáneamente DeepPhase, STA/LTA, probabilidad y latencia. Ante una ventana sin detección se evita afirmar que no existe un sismo; se informa que el umbral no fue alcanzado. Ante evento no detectado se advierte que el resultado no es suficiente para producción.

7. Limitaciones, riesgos y ética

- Las señales sintéticas no representan toda la geología, instrumentación, ruido ni distribución de magnitudes de Guatemala. La métrica sintética no es evidencia de desempeño operacional.
- La detección P no estima por sí sola magnitud, epicentro ni intensidad. La onda S puede llegar antes por geometría y distancia; "anticipación" debe calcularse con un modelo físico y una red de estaciones.
- Un falso negativo puede retrasar una acción de seguridad; un falso positivo puede detener una operación costosa. Por eso se reporta el valor y no solo F1.
- No se deben conectar salidas del prototipo a maquinaria, gas o alarmas públicas. Se requiere validación sismológica, redundancia, fail-safe, calibración por estación, observabilidad y certificación.
- STEAD y FDSN/IRIS deben citarse y usarse conforme a sus licencias y condiciones. No se incluyen datos personales ni credenciales.

8. Iteraciones y trabajo futuro

La iteración I0 es STA/LTA; I1 agrega el extractor de características y MLP; I2 incorpora tres componentes y selección por umbral; I3 será fine-tuning de una red de picking con STEAD y validación regional. En la siguiente fase se deben comparar CNN 1-D, PhaseNet y EQTransformer, medir curvas precisión–recall, calibración, error por SNR y desempeño por estación, y consultar FDSN/IRIS para eventos guatemaltecos. Finalmente se debe desplegar un servicio de streaming con ventanas solapadas, confirmación multiestación y un simulador del paro de maquinaria.

9. Conclusión y reproducción

AlertaP convierte la propuesta en un producto ejecutable de extremo a extremo: señal → procesamiento → modelo → alerta → valor. La comparación justa STA/LTA/DeepPhase con costos explícitos muestra que, en datos sintéticos de alta señal/ruido, el baseline clásico basta; el valor del deep learning debe demostrarse con datos reales (STEAD) o condiciones de ruido más exigentes, que es el trabajo pendiente. El código está en: https://github.com/AngelEsquit/PRYF-DL

```
python3 -m venv .venv
.venv/bin/pip install -r requirements.txt
.venv/bin/pytest -q
.venv/bin/python src/evaluate.py
.venv/bin/streamlit run src/app.py
```