Proyecto Final

CC3092 Deep Learning y Sistemas Inteligentes

1. Descripción general

El proyecto final consiste en construir una implementación real de una tecnología basada en deep learning y demostrar, con números, cuánto valor de negocio genera mejorar sus métricas de entrenamiento. El tema es libre: puede ser visión por computadora, NLP, series de tiempo, sistemas de recomendación, IA generativa, aprendizaje por refuerzo o una combinación.

La pregunta central que cada grupo debe responder es: **si mi modelo mejora en la métrica X, ¿qué cambia para el negocio o para el usuario?** Por ejemplo: cuánto dinero adicional (o cuánta pérdida evitada) trae subir el F1-score de 0.82 a 0.88 en un detector de fraude; cuántas horas de revisión manual se ahorran al reducir el RMSE de un pronóstico de demanda; cuánto mejora la retención o la satisfacción del usuario cuando un recomendador sube su recall.

El proyecto debe traducir la curva de entrenamiento en una curva de valor: costos de errores (falsos positivos vs. falsos negativos), umbrales de decisión, latencia, costo de cómputo y experiencia de usuario.

2. Información clave

Aspecto	Detalle
Modalidad	Grupos de 1, 2 o 3 personas
Presentación en vivo (presencial)	Semana del 16 de noviembre de 2026 (calendario de turnos por confirmar)
Entrega del trabajo escrito	Miércoles 18 de noviembre de 2026
Tecnología	Cualquier modelo o sistema basado en deep learning: CNN, RNN/LSTM, Transformers, autoencoders, GANs, modelos de difusión, LLMs, Deep RL, entre otros
Producto	Implementación funcional y desplegada (API, aplicación web o móvil, bot, dashboard, servicio batch, integración con un sistema existente)
Métricas obligatorias	Métricas técnicas del modelo + al menos una métrica de negocio o de experiencia de usuario, con el vínculo entre ambas cuantificado
Entregables	Trabajo escrito, repositorio de GitHub, video de demostración (2 a 4 minutos, .mp4) y material de apoyo para la presentación

Rúbrica

Componente	Puntos
Trabajo escrito	10
Presentación – Creatividad	3
Presentación – Viabilidad	4
Presentación – Vínculo métrica técnica ↔ resultado de negocio	4
Presentación – Dominio técnico	4
Total	**25**

3. Requisitos mínimos

- **Implementación real:** el modelo debe estar integrado en un flujo utilizable de punta a punta (entrada → preprocesamiento → modelo → decisión o salida que alguien usa). No se aceptan notebooks sueltos como producto final.
- **Deep learning en el núcleo:** el componente que genera el valor debe ser un modelo de deep learning entrenado, ajustado (fine-tuning, LoRA) o adaptado por el grupo. Un LLM vía API sin trabajo adicional de adaptación ni evaluación no es suficiente.
- **Modelo de valor:** debe existir una función explícita que traduzca métricas técnicas (accuracy, F1, recall, RMSE, MAE, mAP, BLEU, puntaje promedio, latencia, etc.) en métricas de negocio (ingresos, costos, horas ahorradas, conversión, retención, satisfacción, riesgo). Los supuestos de esa función deben estar documentados y justificados.
- **Al menos dos versiones del modelo comparadas en valor:** no solo "el modelo B tiene mejor F1", sino "el modelo B genera X dólares adicionales al mes frente al modelo A, con este costo extra de cómputo".
- **Escenario real:** usuario, organización o proceso concreto (real o realista y bien fundamentado), con datos reales o representativos y restricciones reales: volumen, latencia, costo, privacidad.
- **Medible y reproducible:** conjunto de prueba separado, métricas reportadas con su incertidumbre cuando aplique y un repositorio que permita reproducir los resultados.

Ejemplos de casos de uso (solo como inspiración)

Caso de uso	Métrica técnica	Métrica de negocio / UX
Detección de fraude en transacciones	Recall, precisión, F1 por umbral	Pérdida evitada por fraude vs. costo de bloquear transacciones legítimas
Pronóstico de demanda para un comercio o restaurante	RMSE, MAPE	Inventario desperdiciado, ventas perdidas por quiebre de stock
Control de calidad visual en una línea de producción	Recall de defectos, falsos positivos, latencia	Productos defectuosos que llegan al cliente, paros de línea, inspecciones manuales evitadas

Caso de uso	Métrica técnica	Métrica de negocio / UX
Clasificación y enrutamiento de tickets o correos	F1 macro, exactitud por clase	Tiempo de primera respuesta, horas de agente ahorradas, satisfacción del cliente
Sistema de recomendación	Recall@k, NDCG	Tasa de clics, conversión, ticket promedio
Predicción de abandono (churn)	AUC, recall en el top 10 %	Clientes retenidos por campaña, retorno de la campaña de retención
Asistente RAG sobre documentación interna	Recall@k, fidelidad, tasa de alucinaciones	Tickets de soporte evitados, tiempo de búsqueda ahorrado
Agente de RL para precios, control o asignación de recursos	Recompensa promedio	Margen, consumo energético, utilización de recursos
OCR y extracción de documentos (facturas, formularios)	Exactitud por campo, CER	Horas de digitación ahorradas, errores contables evitados

4. Estructura del trabajo escrito

El trabajo escrito debe incluir las siguientes secciones.

4.1 Contexto de negocio y definición del problema

- ¿Qué organización, usuario o proceso se beneficia? ¿Cómo se resuelve el problema hoy y cuánto cuesta (dinero, tiempo, errores)?
- ¿Por qué deep learning? ¿Se consideró una alternativa más simple (reglas, modelos clásicos)? Justifica la complejidad.
- KPIs de negocio que el proyecto busca mover y su valor actual (línea base).

4.2 Datos y análisis exploratorio

- Fuentes, volumen, formato, calidad y representatividad respecto al escenario real.
- EDA: distribuciones, desbalance de clases, valores nulos, atípicos, sesgos y fugas de información.
- Preprocesamiento y su justificación; estrategia de división train/validation/test que imite el uso real.
- Consideraciones de privacidad y licencias de los datos si aplica.

4.3 Modelo de valor

- Función de valor explícita. Ejemplo para clasificación: valor = VP × beneficio por acierto − FP × costo por falsa alarma − FN × costo por caso no detectado − costo de operación.
- Supuestos y fuentes de cada parámetro (costos, precios, volúmenes); dónde son estimaciones.
- Curva de valor: cómo cambia el valor de negocio al variar la métrica técnica o el umbral de decisión.

- Análisis de sensibilidad: ¿qué pasa si los supuestos están 20 % o 50 % equivocados?
- Selección del umbral o punto de operación óptimo según valor, no solo según la métrica técnica.

4.4 Metodología de desarrollo

- Arquitectura(s) consideradas y justificación de la final (relación con lo visto en clase).
- Función de pérdida y su alineación con el objetivo de negocio (por ejemplo, pérdida ponderada por costo de error).
- Optimizador, tasa de aprendizaje, regularización y demás hiperparámetros; estrategia de búsqueda.
- Uso de modelos preentrenados y fine-tuning, con su costo computacional.

4.5 Resultados de iteraciones

Se recomienda una tabla con una fila por iteración:

- Identificador y cambios respecto a la anterior.
- Métricas técnicas en entrenamiento, validación y prueba.
- **Valor de negocio estimado** con la función de la sección 4.3.
- Costo de entrenamiento e inferencia (tiempo, GPU, dinero).
- Curvas de entrenamiento de las iteraciones relevantes y evidencia de problemas encontrados (overfitting, inestabilidad, desbalance) y cómo se abordaron.

4.6 Despliegue y experiencia de usuario

- Arquitectura del sistema desplegado (diagrama): entrada, preprocesamiento, modelo, post-procesamiento, interfaz o integración.
- Métricas operativas: latencia, throughput, costo por predicción.
- Cómo mejores resultados del modelo cambian la experiencia del usuario (menos pasos, menos esperas, menos correcciones manuales). Si es posible, evidencia con usuarios reales: prueba de usabilidad, encuesta o prueba A/B.
- Manejo de errores, casos límite y cómo se comunica la incertidumbre del modelo al usuario.
- Plan de monitoreo: cómo se detectaría degradación en producción.

4.7 Explicabilidad, ética y riesgos

- Herramientas de explicabilidad aplicadas (SHAP, Grad-CAM, mapas de atención, etc.) y qué revelan sobre el modelo.
- Sesgos en datos y predicciones: ¿el modelo funciona peor para algún grupo? ¿Cuál es el costo de negocio y humano de esos errores?
- Riesgos de uso indebido, privacidad y situaciones en las que el sistema **no** debería usarse.

4.8 Discusión y conclusiones

- Qué cambios tuvieron mayor impacto en el valor de negocio (no siempre coinciden con los de mayor impacto en la métrica técnica).
- Punto de rendimientos decrecientes: ¿cuándo deja de valer la pena mejorar el modelo?
- Trade-off entre complejidad del modelo, costo y valor generado.
- Limitaciones, viabilidad de llevarlo a producción real y siguientes pasos.

4.9 Enlace al repositorio de GitHub

Repositorio público con: preprocesamiento, entrenamiento, evaluación, modelo de valor, código de la aplicación desplegada y un README que explique cómo instalar, ejecutar y reproducir las métricas reportadas.

5. Presentación en vivo

Durante la semana del 16 de noviembre de 2026, cada grupo presentará su proyecto en el turno que se le asigne. La dinámica será la siguiente:

1. **Pitch (8 a 10 minutos):** problema y usuario, por qué deep learning, modelo de valor, resultados de iteraciones y conclusión de negocio.
2. **Demostración en vivo (3 a 5 minutos):** el sistema funcionando con entradas reales o representativas, incluyendo al menos una entrada que no forme parte del conjunto de entrenamiento y, si es posible, una entrada propuesta por el catedrático.
3. **Preguntas técnicas (5 minutos):** cualquier integrante debe poder responder sobre cualquier parte del proyecto: datos, arquitectura, entrenamiento, modelo de valor y despliegue.

Criterios de evaluación de la presentación

Criterio	Puntos	¿Qué se evalúa?
Creatividad	3	Originalidad del problema y de la solución. Se valora ir más allá de aplicar un modelo estándar a un dataset público conocido.
Viabilidad	4	Qué tan realista es llevar el sistema a producción: datos disponibles, costos de cómputo e inferencia, latencia, mantenimiento, riesgos regulatorios y de adopción. ¿Lo pagaría alguien?
Vínculo métrica ↔ negocio	4	Claridad y rigor del modelo de valor: supuestos justificados, curva de valor, análisis de sensibilidad y elección del punto de operación según valor.
Dominio técnico	4	Comprensión de la arquitectura, del proceso de entrenamiento y de las decisiones tomadas; calidad de la demo y capacidad de explicar fallas del modelo.